UNIVERSIDADE DO VALE DO ITAJAÍ
CIÊNCIA DA COMPUTAÇÃO – ESTRUTURA DE DADOS
PROF. MSc. EDUARDO ALVES DA SILVA

GUSTAVO HENRIQUE STAHL MÜLLER

PARALELIZAÇÃO DE TRANSFORMAÇÕES LINEARES E SOMATÓRIOS DE VETOR COM OPENMP E PTHREADS

ITAJAÍ
2021

SUMÁRIO

1. INTRODUÇÃO

Esse trabalho demonstra dois algoritmos: transformações lineares e somatórios de vetor, sendo paralelizados de duas maneiras diferentes, em C++.

Uma das maneiras é usando OpenMP, uma interface de código aberto para paralelização de algoritmos em alto nível, e a segunda é atraves de Pthreads, mais especificamente, sua implementação para Windows (WIN_PTHREADS_H).

O repositório de código está disponível em: https://github.com/GustavoHenriqueMuller/parallel-algorithms

2. DESENVOLVIMENTO

Essa seção contém a explicação dos dois algoritmos e suas resoluções em código.

2.1. TRANSFORMAÇÕES LINEARES

A aplicação de uma transformação linear, também conhecida como multiplicação de matrizes, é um algoritmo de alta importância para a ciência da computação. Através dele, é possível determinar posições de vetores após serem transformados por uma matriz que possui vetores que representam a base de um espaço vetorial.

Isso é extremamente útil para a computação gráfica, já que transformações lineares podem representar uma multitude de processamentos gráficos, incluindo, mas não limitado à, rotação e mudança de escala de imagens ou objetos.

Através de uma matriz que representa os vetores que compõem o objeto, e através de outra matriz que transforma esses vetores de uma certa maneira, o resultado da mulitplicação dessas duas matrizes será os vetores originais do objeto depois da transformação. É importante notar que multiplicação de matrizes é originalmente lida da direita para a esquerda, logo, a primeira matriz é aquela mais à direita.

No exemplo abaixo, a primeira matriz é composta por somente um vetor que indica a extremidade do bloco (vetor [1,1]). A segunda matriz, chamada de T e definida na figura, indica que o *x* da primeira matriz (1) será multiplicado pelo vetor [-2,0], e que o *y* da primeira matriz (1) será multiplicado pelo vetor [0, -2].

Isso resulta no vetor [-2, -2], que representa a extremidade do bloco após sofrer a transformação.

Figura 1 – Transformação linear de inversão e ampliação sendo aplicada em um bloco.
Fonte: Math Insight.

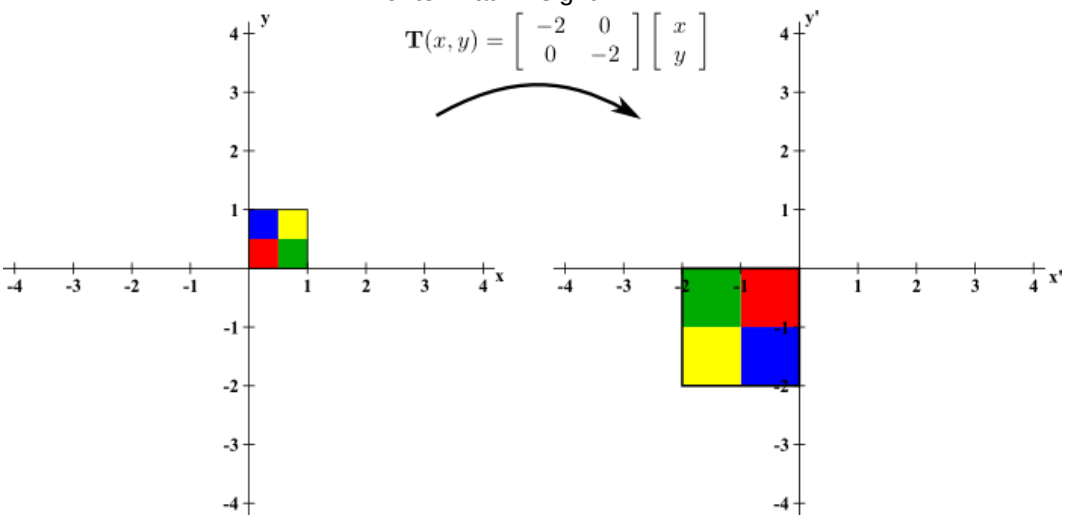

2.1.1 EM CÓDIGO

A aplicação de transformações lineares de maneira sequencial é dada por:

Figura 2 – Transformação linear de maneira sequencial.
Fonte: O autor.

```
// Multiplies AxB
for(long i = 0; i < aRows; i++) {
    for(long j = 0; j < bCols; j++) {
        for(long k = 0; k < aCols; k++) {
            res[i][j] += a[i][k] * b[k][j];
        }
    }
}
```

O código passa por cada valor de cada linha de A e multiplica por cada valor de cada coluna de B, e soma todas essas multiplicações para formar um dos resultados finais da matriz de resposta.

Em OpenMP, a única alteração à ser feita é o uso de uma diretiva que separa o trabalho de passar por cada linha de A entre várias threads diferentes, para alcançar melhor desempenho:

Figura 3 – Transformação linear em OpenMP.
Fonte: O autor.

```
// Multiplies AxB
#pragma omp parallel for num_threads(threadNum)
for(long i = 0; i < aRows; i++) {
    for(long j = 0; j < bCols; j++) {
        for(long k = 0; k < aCols; k++) {
            res[i][j] += a[i][k] * b[k][j];
        }
    }
}
```

Por último, em Pthreads, o código é mais complexo devido ao menor nível de abstração oferecido. Primeiro, é preciso criar um conjunto de threads e definir qual é a sua função alvo. Como argumento dessa função, é passado um *buffer* alocado dinâmicamente que representa o índice da iteração atual. Isso será usado depois para calcular o intervalo de linhas que cada thread deve operar sobre.

Figura 4 – Criação de *threads*.
Fonte: O autor.

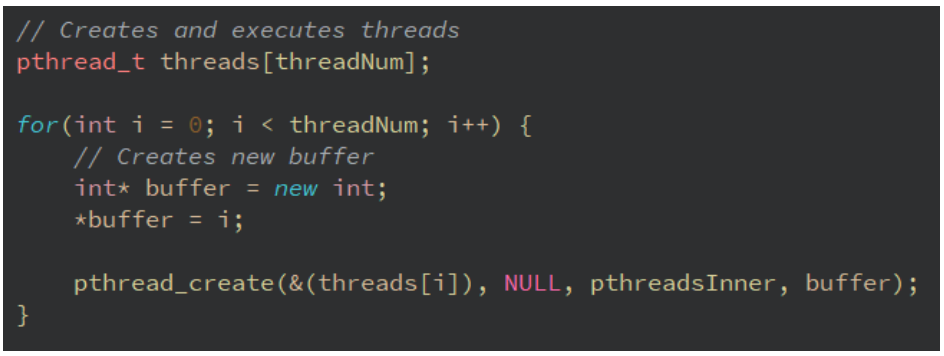

```
// Creates and executes threads
pthread_t threads[threadNum];

for(int i = 0; i < threadNum; i++) {
    // Creates new buffer
    int* buffer = new int;
    *buffer = i;

    pthread_create(&(threads[i]), NULL, pthreadsInner, buffer);
}
```

Após a criação e início das *threads*, é calculado o tamanho do bloco, que é a quantidade de linhas da primeira matriz dividido pela quantidade de *threads*. O intervalo de linhas também é calculado à partir desse tamanho de bloco. O *buffer* mencionado anteriormente também é desalocado após ser utilizado:

Figura 5 – Criação de variáveis locais à *thread*.
Fonte: O autor.

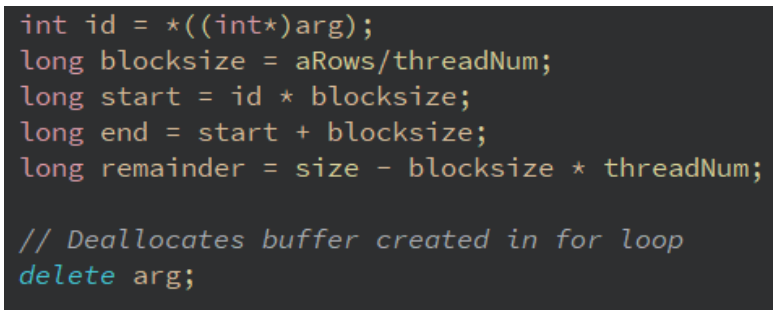

```
int id = *((int*)arg);
long blocksize = aRows/threadNum;
long start = id * blocksize;
long end = start + blocksize;
long remainder = size - blocksize * threadNum;

// Deallocates buffer created in for loop
delete arg;
```

A multiplicação acontece no intervalo calculado anteriormente (*start* até *end*):

Figura 6 – Multiplicação de matrizes feita por cada *thread* em seu intervalo respectivo.
Fonte: O autor.

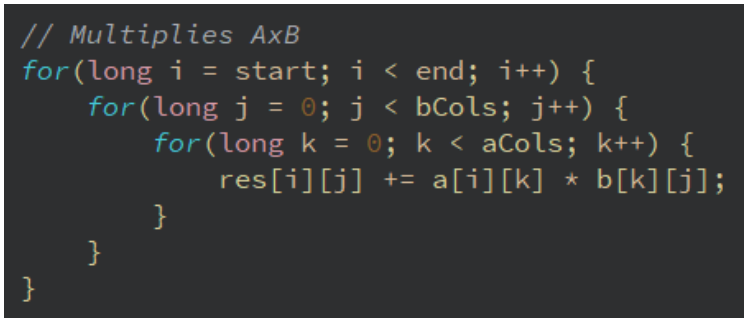

```
// Multiplies AxB
for(long i = start; i < end; i++) {
    for(long j = 0; j < bCols; j++) {
        for(long k = 0; k < aCols; k++) {
            res[i][j] += a[i][k] * b[k][j];
        }
    }
}
```

Por último, uma variável de resto (*remainder*) é calculada. Ela representa a quantidade de linhas da matriz que não foram pegas por nenhuma *thread*. Isso acontece quando o tamanho do bloco não é um número inteiro. Essa era uma situação que o OpenMP tratava automaticamente, mas com Pthreads, precisa ser lidada manualmente.

Para lidar com essa situação, utilizei um algoritmo muito simples: As linhas que não foram pegas por nenhuma thread são sequencialmente multiplicadas pela primeira thread criada. Esse algoritmo não é o mais efetivo, pois caso muitas casas não forem pegas, grande parte do algoritmo será sequencial e não paralelo, prejudicando o desempenho.

As linhas não pegas sempre serão as últimas, então é possível deduzir a posição da primeira linha através da quantidade de linhas não pegas e do tamanho de linhas. Esse valor representa o índice da linha de início (*start*):

Figura 7 – Lidando com linhas não pegas por threads.
Fonte: O autor.

```
// Deals with remaining positions
if(id == 0) {
    while(remainder > 0) {
        start = (size - remainder);

        for(long i = start; i < aRows; i++) {
            for(long j = 0; j < bCols; j++) {
                for(long k = 0; k < aCols; k++) {
                    res[i][j] += a[i][k] * b[k][j];
                }
            }
        }

        remainder--;
    }
}
```

Finalmente, basta juntar todas as *threads*, assim garantindo a integral multiplicação das matrizes, consequentemente finalizando o algoritmo:

Figura 8 – Juntando todas as *threads*.
Fonte: O autor.

```
// Joins all threads
for(int i = 0; i < threadNum; i++) {
    pthread_join(threads[i], 0);
}
```

2.1.1 COMPARAÇÕES

A tabela abaixo mostra uma comparação dos tempos de execução das três implementações diferentes de aplicação de transformações lineares. As seguintes propriedadaes se aplicam aos testes:

- A multiplicação foi feita entre duas matrizes quadradas de mesmo tamanho.
- 4 *threads* foram usadas para OpenMP/Pthreads.
- O código executou em um processador i5-10400F, de 6 núcleos e uma frequência de 2.90 GHz até 4.30 GHz.

Tabela 1 – Tempos de execução para Transformações Lineares.
Fonte: O autor.

	100 x 100 elementos	**1000 x 1000 elementos**	**2000 x 2000 elementos**
Sequencial	0.0039s	4.227s	18.33s
OpenMP	0.0009s (~23%)	1.008s (~23%)	4.511s (~24%)
Pthreads	0.002s (~51%)	1.135s (~26%)	4.754s (~25%)

A porcentagem em parênteses das implementações paralelas representa a razão do tempo em relação ao tempo sequencial.

2.2. SOMATÓRIO DE VETOR

O somatório de todos os elementos de um vetor é um algoritmo simples, porém muito utilizado. Através do somatório, e então da divisão entre ele e a quantidade de elementos, a média aritmética simples do vetor é calculada.

Com uma leve alteração do algoritmo, é possível que ele também compute médias aritméticas ponderadas, sendo que essas duas médias possuem amplo uso em estatística e servem de base para muitos outros conceitos, como variância, desvio médio e desvio padrão.

2.2.1 EM CÓDIGO

O somatório de um vetor de maneira sequencial é dado por:

Figura 9 – Somatório de vetor de maneira sequencial.
Fonte: O autor.

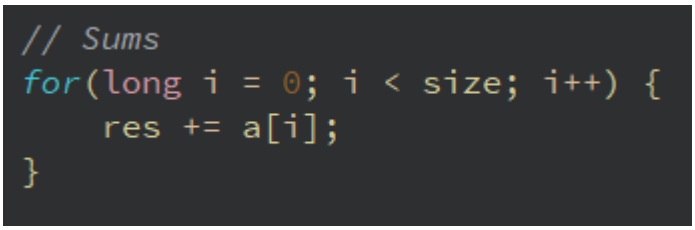

```
// Sums
for(long i = 0; i < size; i++) {
    res += a[i];
}
```

O código passa por cada valor do vetor e soma ele à variável de resultado, chamada de *res*.

Em OpenMP, o algoritmo permanece igual, porém é necessário usar uma diretiva que separa o trabalho do *for* igualmente para as *threads*, e também a aplicação de *reduction*, que evita a situação onde várias *threads* tentam escrever o seu resultado para a variável *res* ao mesmo tempo, causando somas incorretas.

Figura 10 – Soma de vetor em OpenMP.
Fonte: O autor.

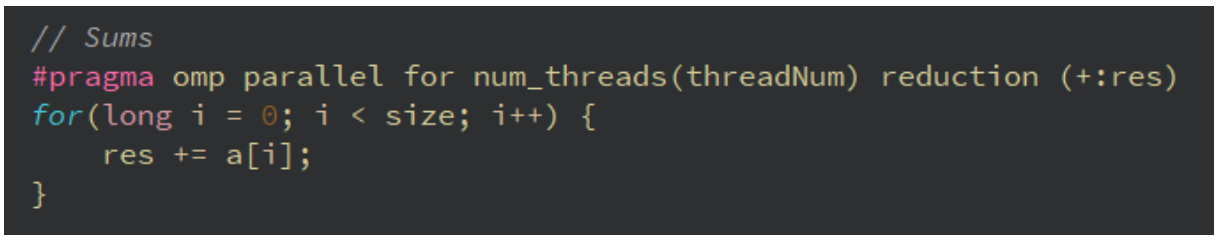

```
// Sums
#pragma omp parallel for num_threads(threadNum) reduction (+:res)
for(long i = 0; i < size; i++) {
    res += a[i];
}
```

Em Pthreads, os algoritmos de cálculo de tamanho de bloco e o tratamento de espaços não pegos por threads são os mesmos da transformação linear. A única diferença entre essa implementação e a implementação sequencial é que cada *thread* possui uma variável de soma privada. Quando o algoritmo termina, essa variável de soma privada é somada à variável compartilhada de resultado (*res*).

Isso evita que a variável de soma compartilhada seja travada constantemente para evitar a situação de que duas *threads* escrevem nela ao mesmo tempo.

Essa situação era corrigida automaticamente com a cláusula *reduction* em OpenMP, mas deve ser corrigida manualmente em Pthreads pelas funções *pthread_mutex_lock() e pthread_mutex_unlock()*, que devem ser chamadas antes e depois que uma *thread* escreva à uma variável compartilhada, respectivamente.

Figura 11 – Soma realizada à variável privada à *thread* (localSum), que é posteriormente somada à variável de resultado compartilhada.
Fonte: O autor.

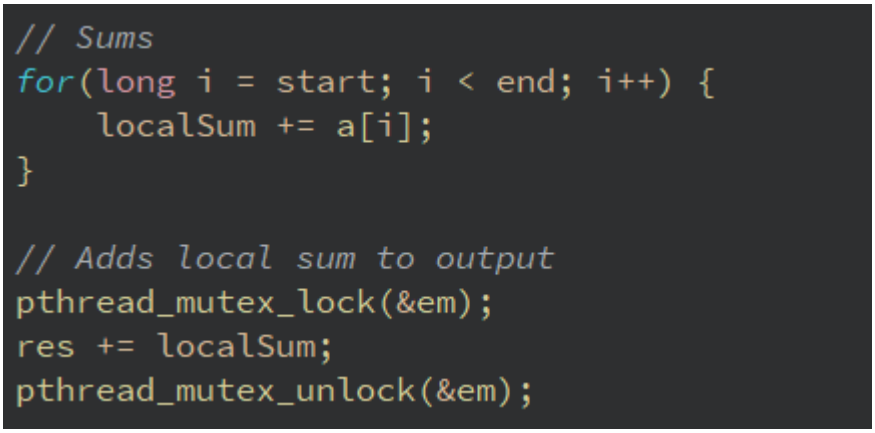

2.2.2 COMPARAÇÕES

A tabela abaixo mostra uma comparação dos tempos de execução das três implementações diferentes de somatório de vetor. As seguintes propriedadaes se aplicam aos testes:

- 4 *threads* foram usadas para OpenMP/Pthreads.
- O código executou em um processador i5-10400F, de 6 núcleos e uma frequência de 2.90 GHz até 4.30 GHz.

Tabela 1 – Tempos de execução para Transformações Lineares.
Fonte: O autor.

	10.000.000 elementos	**100.000.000 elementos**	**160.000.000 elementos**
Sequencial	0.056s	0.571s	0.876s
OpenMP	0.023s (~41%)	0.219s (~38%)	0.348s (~39%)
Pthreads	0.021s (~37%)	0.218s (~38%)	0.348s (~39%)

A porcentagem em parênteses das implementações paralelas representa a razão do tempo em relação ao tempo sequencial.

3 CONCLUSÃO

3.1 OPINIÃO

Com certeza é possível perceber a diferença de desempenho entre os algoritmos sequenciais e paralelos. O maior ganho ocorreu na transformação linear de duas matrizes 1000x1000 usando OpenMP, que obteve um tempo de somente 23% do tempo de execução original (ganho de ~4.34x).

No geral, OpenMP e Pthreads tiveram um ganho de desempenho muito próximo, mas considero OpenMP melhor para uso real pois ele fornece uma interface abstrata, relativamente simples e de fácil entendimento, em contraste à Pthreads, que oferece funções de mais baixo nível.